

D 题 第四问：额外商业决策与危机处理 模型思路

（里面的数值均需自行调整）

8. 第四问：额外商业决策与危机处理模型构建

第四问作为前三问模型的延伸与落地补充，核心解决两大核心场景：一是在联盟扩张、球员收购策略落地的基础上，通过**额外商业决策优化**进一步提升球队双目标（利润、品牌估值）；二是应对职业体育中高频突发的**核心球员伤病危机**，通过动态策略调整降低损失、维持球队运营稳定性。

本章节模型严格衔接前三问核心逻辑：以第三问修正后的目标函数、约束条件为基础，复用 LSTM 时序预测、MARL 等高级算法，新增多目标强化学习（MO-MARL）、注意力机制 LSTM（Attention-LSTM）等高级算法适配场景需求；所有量化过程均依托提供的数据字段（attendance_data.csv、model_parameters.csv 等 8 份数据），明确数据字段的应用场景与关联逻辑，确保模型与前文无缝衔接、逻辑严密、可落地。

核心建模思路：先完成“额外商业决策”建模（选取票务定价动态优化为核心场景，贴合数据字段与前三问商业决策模块），再完成“伤病危机应对”建模（聚焦核心球员伤病后的动态调整），最后通过算法集成实现双场景的协同求解与验证，确保模型既适配常规运营优化，也能应对突发危机。

8.2 额外商业决策建模（核心场景：票务定价动态优化）

结合前三问商业决策模块的票务定价基础，进一步深化为**时序动态定价**（考虑不同赛季、不同场次、不同对手的差异），突破前三问“单一固定调整系数”的局限，实现精细化定价优化。本场景选取票务定价优化，核心依托 attendance_data.csv、model_parameters.csv、team_valuations.csv 等数据字段，通过高级算法实现“需求预测-定价优化-收益最大化”的闭环。

8.2.1 场景假设与核心变量定义

8.2.1.1 场景假设

- 假设定价优化覆盖常规赛、季后赛所有场次，区分主场/客场（客场定价由主队主导，本模型聚焦主队主场定价）；
- 定价调整需兼顾短期门票收益与长期季票持有者培养；

8.2.1.2 核心变量定义

- 决策变量： $P_{t,m}$ ——第 t 个赛季、第 m 场主场比赛的票务定价调整系数；
 - 状态变量： $X_{t,m}=[S_{market,t}, A_{t,m}, O_{t,m}, C_{util,t}, P_{t,m-1}, H_{t,m}]$ ，其中：
 - $S_{market,t}$ ——第 t 赛季球队市场份额（来自第三问 5.1.1 节计算结果）；
 - $A_{t,m}$ ——第 t 赛季第 m 场比赛的预期上座率（待预测变量）；
 - $O_{t,m}$ ——对手球队热度系数（由 `team_valuations.csv` 的 `valuation_2025_M`、`attendance_data.csv` 的对手场均上座率量化）；
 - $C_{util,t}$ ——第 t 赛季场馆平均利用率（来自 `attendance_data.csv` 的 `capacity_utilization`）；
 - $P_{t,m-1}$ ——上一场比赛定价调整系数（体现时序关联性）；
 - $H_{t,m}$ ——主场优势系数（由 `team_valuations.csv` 的 `city_population_M`、球队主场胜率量化）。
- 输出变量： $\Delta R_{ticket,t,m}$ ——第 t 赛季第 m 场比赛门票净收益增量； $P_{t,m}^*$ ——最优定价调整系数； $S_{season,t}$ ——第 t 赛季季票持有者增长率（长期目标关联变量）。

8.2.2 数据字段适配（明确数据来源与应用方式）

本模块核心复用以下数据字段，确保与现有数据强关联，不引入无数据支撑的参数：

1. attendance_data.csv:

`avg_attendance`、`total_attendance`：用于校准预期上座率 $A_{t,m}$ 的基准值；

`capacity_utilization`：用于约束上座率不超过场馆容量，同时作为状态变量 $C_{util,t}$ ；

`arena_capacity`：用于设定上座率上限约束。

2. model_parameters.csv:

`ticket_price_elasticity`：票价弹性系数 ϵ ，用于量化定价与需求的关系（复用前三问逻辑， $\epsilon = -\text{ticket_price_elasticity}$ ）；

`sponsorship_growth_rate`：用于校准季票持有者增长带来的长期收益系数。

3. team_valuations.csv:

`city_population_M`：量化主场优势系数 $H_{t,m}$ ，城市人口越多，主场优势越明显；

`valuation_2025_M`：量化对手球队热度系数 $O_{t,m}$ ，对手估值越高，比赛热度越高；

`yoy_valuation_change_pct`：用于校准定价优化对品牌估值的长期带动作用。

4. salary_cap_history.csv: annual_increase_pct: 用于同步调整定价的年度基准涨幅，与联盟整体发展节奏匹配。

8.2.3 目标函数构建（双目标：短期净收益+长期季票增长）

结合前三问“利润+估值”双目标，本模块构建票务定价的双目标函数，兼顾短期收益与长期品牌增值

短期目标（首要）：最大化单场门票净收益增量 $\Delta R_{ticket,t,m}$ ，公式延续前三问并优化时序关联性：

$$\Delta R_{ticket,t,m} = (P_{t,m} \cdot D_{t,m} \cdot P_{t,m}^e \cdot S_{market,t} - C_{ticket,t,m}) - (D_{t,m} \cdot S_{market,t})$$

其中： $D_{t,m}$ ——第 t 赛季第 m 场比赛的基准上座人次（由 attendance_data.csv 的 avg_attendance 结合对手热度 $O_{t,m}$ 校准）； $C_{ticket,t,m}$ ——第 t 赛季第 m 场比赛的定价调整成本（优化为时序动态成本， $C_{ticket,t,m} = \lambda_{ticket} \cdot |\Delta R_{ticket,t,m}| \cdot (1 + 0.05 \cdot (m/T_t))$ ， T_t 为第 t 赛季主场总场次，m 越大（赛季后期），调整成本越高，贴合实际运营）； λ_{ticket} ——调整成本系数（复用前三问校准值，可通过 model_parameters.csv 的参数微调）。

长期目标（次要）：最大化季票持有者增长率 $S_{season,t}$ ，公式关联定价策略与季票吸引力：

$$S_{season,t} = \gamma_{season} \cdot \frac{1}{T_t} \sum_{m=1}^{T_t} (P_{t,m} \cdot 0.95) \cdot C_{util,t} \cdot S_{market,t}$$

其中， γ_{season} ——季票增长系数（由 team_valuations.csv 的 yoy_valuation_change_pct 校准，体现定价对长期粉丝留存的带动作用）。

双目标融合：

$$\max F(P_{t,m}) = 0.7 \cdot \frac{\Delta R_{ticket,t,m}}{\Delta R_{max}} + 0.3 \cdot \frac{S_{season,t}}{S_{season,max}}$$

其中， ΔR_{max} 、 $S_{season,max}$ 分别为短期净收益增量、季票增长率的理论最大值，加权系数可根据第三问的目标权重动态调整。

8.2.4 约束条件

约束条件延续前三问的核心逻辑，新增时序定价、季票保护等约束，确保模型合规、可行：

1. 定价范围约束： $0.7 \leq P_{t,m} \leq 1.6$ （适配不同场次热度差异，参考数值，需自行调整）；
2. 上座率约束： $A_{t,m} = D_{t,m} \cdot P_{t,m}^e \cdot S_{market,t} \leq arena_capacity$ （来自 attendance_data.csv 的场馆容量）；
3. 时序定价约束： $|P_{t,m} - P_{t,m-1}| \leq 0.1$ （相邻场次定价调整幅度不超过 10%，避免定价波动过大影响粉丝信任）；

4. 季票保护约束：季票定价不高于单场最优定价的 90%，即

$P_{season,t} \leq 0.9 \cdot P_{t,m}^*$ ($P_{season,t}$ 为第 t 赛季季票定价系数，确保季票持有者权益)；

5. 市场份额联动约束： $P_{t,m} \leq 1.2 \cdot S_{market,t}/S_{market,min}$ （市场份额越低，定价上限越低，贴合小市场球队运营逻辑， $S_{market,min}$ 为联盟最低市场份额）。

8.2.5 算法设计（Attention-LSTM+贝叶斯优化）

本模块采用“时序预测+连续决策优化”的双算法组合，既解决上座率的时序预测问题，又实现定价系数的精准优化，较前三问的算法更具针对性，同时与前文 LSTM、贝叶斯优化算法衔接，确保算法一致性：

1. 第一步：Attention-LSTM 时序预测（上座率预测）

核心功能：预测第 t 赛季第 m 场比赛的预期上座率 $A_{t,m}$ ，解决时序数据的长短期依赖问题（如赛季初期、中期、后期的上座率差异，对手热度的动态变化）；

输入特征：选取状态变量中的时序相关特征 $[A_{t,1}, A_{t,2}, \dots, A_{t,m-1}, O_{t,m}, C_{util,t}, H_{t,m}]$ ，数据均来自对应 CSV 文件；

算法优化：在前三问 LSTM 的基础上加入注意力机制，重点关注对手热度、主场优势等关键特征对上座率的影响，提升预测精度；

模型结构：输入层（特征维度=7）→ 注意力层（聚焦关键特征权重）→ LSTM 隐藏层（128 个神经元，ReLU 激活函数）→ 输出层（1 维， $A_{t,m}$ 预测值）；

训练与验证：复用前三问的训练逻辑，以 attendance_data.csv 的历史上座率数据为训练集，5 折交叉验证，确保预测误差 $MAE \leq 8\%$ （优于前三问的 10%，提升预测精度）。

2. 第二步：贝叶斯优化（定价系数优化）

核心功能：基于 Attention-LSTM 预测的 $A_{t,m}$ ，求解双目标函数 $\max F(P_{t,m})$ 的最优定价系数 $P_{t,m}^*$ ；

代理模型与采集函数：复用前三问的高斯过程代理模型，采集函数选用改进 EI 函数（加入双目标权重），平衡探索与利用；

求解流程：初始化采样点（8 个，覆盖定价范围）→ 训练代理模型 → 改进 EI 函数选取下一个采样点 → 迭代更新（迭代次数 ≤ 60 次）→ 输出 $P_{t,m}^*$ 及对应双目标值；

约束适配：采样过程中自动剔除违反约束条件的采样点，确保最优解合规。

8.3 伤病危机应对建模（核心场景：核心球员伤病）

伤病危机是职业体育的高频突发场景，本模块聚焦**核心球员伤病**（超级顶薪、顶薪球员），量化伤病对球队双目标（利润、估值）的冲击，通过动态策略调整降低损失，衔接前三问的球员收购策略、薪资约束与目标函数。本场景核心依托

model_parameters.csv、player_salaries_2025.csv、team_valuations.csv 等数据字段，采用

多目标强化学习实现动态应对。

8.3.1 场景假设与核心变量定义

8.3.1.1 场景假设

- 假设伤病仅针对核心球员（由 player_salaries_2025.csv 的 contract_type 判定：Supermax、max_salary 球员），非核心球员伤病影响可忽略；
- 假设伤病有明确的持续时间（短期：1-10 场，中期：11-30 场，长期：30 场以上），影响程度与持续时间正相关；
- 伤病应对策略需符合联盟规则（薪资帽、阵容人数约束），复用前三问的约束逻辑；
- 伤病冲击可通过现有数据字段量化，核心关联球员商业价值、竞技价值与球队收入。

8.3.1.2 核心变量定义

- 状态变量： $Y_t=[I_t, T_{perf,t}, R_{total,t}, Cap_t, Budget_{acq}', S_{market,t}]$ ，其中：
 I_t ——伤病状态标识（0：无核心伤病，1：短期伤病，2：中期伤病，3：长期伤病）；
 $T_{perf,t}$ ——第 t 赛季球队竞技实力（来自前三问的 $(T_{\{perf\}})$ ，伤病后下降）；
 $R_{total,t}$ ——第 t 赛季球队总收入（含门票、媒体、赞助，伤病后下降）；
 Cap_t ——第 t 赛季薪资帽（来自第三问 LSTM 预测结果）；
 $Budget_{acq}'$ ——修正后的球员收购预算（来自第三问 5.3.2 节）；
 $S_{market,t}$ ——第 t 赛季球队市场份额（来自第三问 5.1.1 节）。
决策变量： $A_t=[a_1, a_2, a_3, a_4]$ （多维度应对策略，0-1 变量或连续变量），其中：
 a_1 ——紧急收购替补策略（0：不收购，1：选秀渠道，2：自由市场，3：交易渠道，复用第二问的收购渠道）；
 a_2 ——票价调整策略（连续变量， $a_2 \in [0.6, 1.0]$ ，伤病后定价调整系数）；
 a_3 ——媒体投入调整策略（连续变量， $a_3 \in [0.5, 1.2]$ ）；
 a_4 ——薪资调整策略（0：不调整，1：调整核心球员薪资（伤病期间降薪），2：调整替补球员薪资）。
输出变量： ΔZ_t ——伤病后球队双目标值变化量（ $\Delta Z_t = Z_t - Z_{t,0}$ ）， $Z_{t,0}$ 为无伤病时的目标函数值）； A_t^* ——最优应对策略组合； L_t ——伤病造成的损失最小化值。

8.3.2 数据字段适配（明确数据来源与应用方式）

本模块核心复用以下数据字段，量化伤病冲击与应对成本，确保模型有数据支撑：

1. model_parameters.csv:

injury_risk_coeff: 伤病风险系数，用于量化核心球员伤病对收入的冲击幅度；

discount_rate: 折现率，用于计算伤病长期损失的现值；

win_rate_revenue_coeff: 胜率收入系数，用于量化伤病导致胜率下降带来的收入损失。

2. player_salaries_2025.csv:

contract_type: 用于识别核心球员（Supermax、max_salary）；

salary_2025: 用于计算核心球员伤病后的薪资成本、替补球员收购成本；

contract_length: 用于量化伤病对长期合同的影响。

3. team_valuations.csv:

valuation_2025_M、yoy_valuation_change_pct: 用于量化伤病对球队品牌估值的冲击；

revenue_2024_M: 用于校准伤病导致的收入损失基准值；

notes: 用于提取球星带动效应（如新秀、顶级球星的伤病影响差异）。

4. 其他数据:

attendance_data.csv 的 avg_attendance: 用于量化伤病导致的上座率下降；

media_deals.csv 的 annual_value: 用于量化伤病导致的媒体收入下降；

salary_cap_history.csv 的 salary_cap、salary_floor: 用于约束伤病后的薪资调整。

8.3.3 伤病冲击量化（分维度：收入+估值+竞技实力）

结合数据字段与前三问的量化逻辑，从三个维度量化核心球员伤病的冲击，确保与第三问修正后的利润 Π' 、品牌估值 $V_{franchise}$ 深度衔接：

1. 竞技实力冲击量化：

$$T_{perf,t}' = T_{perf,t,0} \cdot (1 - \alpha \cdot I_t \cdot \beta) \text{ 其中:}$$

$T_{perf,t,0}$ ——无伤病时第 t 赛季球队竞技实力（来自前三问计算结果）；

α ——核心球员竞技权重（由 player_salaries_2025.csv 的 salary_2025 占球队总薪资的比例量化）；

β ——伤病严重程度系数（短期：0.2，中期：0.5，长期：0.8，由伤病持续时间校准）。

2. 收入冲击量化（复用第三问收入结构，修正伤病影响）：

$$R_{total,t}' = \left(R_{win,t,0} \cdot (1 - \text{injury_risk_coeff} \cdot I_t) + R_{star,t,0} \cdot (1 - 0.15 \cdot I_t) + \Delta R_{business,t,0} \cdot (1 - 0.1 \cdot I_t) \right) \cdot S_{market,t}$$

其中，injury_risk_coeff 来自 model_parameters.csv，分别量化竞技收入、商业收入、商业决策净收益的伤病损失，核心球员伤病对商业收入（球星带动）的冲击最大（15%）。

3. 品牌估值冲击量化（延续第三问估值逻辑）：

$V_{franchise,t}' = V_{franchise,t,0} \cdot (1 - \gamma \cdot I_t \cdot \delta)$ 其中：

γ ——球星估值权重（由 team_valuations.csv 的 yoy_valuation_change_pct 校准，球星带动效应越强， γ 越大）；

δ ——估值冲击衰减系数（ $\delta=0.8$ ，长期估值冲击随时间衰减）。

总冲击量化： $\Delta Z_t = (w_1 \cdot \Pi_t' + w_2 \cdot V_{franchise,t}') - (w_1 \cdot \Pi_{t,0}' + w_2 \cdot V_{franchise,t,0}')$ ， $\Delta Z_t < 0$ 表示损失，目标是最小化 $|\Delta Z_t|$ 。

8.3.4 目标函数构建（多目标：损失最小化+应对成本最小化）

伤病应对的核心目标是“双最小化”，既降低伤病带来的双目标损失，又控制应对策略的执行成本，构建多目标函数，与前三问的双目标逻辑保持一致：

$$\min G(A_t) = 0.6 \cdot \frac{|\Delta Z_t|}{|\Delta Z_{\max}|} + 0.4 \cdot \frac{C_{response,t}}{C_{response,max}}$$

其中：

$C_{response,t}$ ——伤病应对总成本（多策略组合成本），公式为：

$$C_{response,t} = C_{acq,t} + C_{price,t} + C_{media,t} + C_{salary,t}$$

各分项成本均来自对应数据字段：

$C_{acq,t}$ ——紧急收购替补成本（来自 player_salaries_2025.csv 的 salary_2025，结合第二问的收购成本公式）； $C_{price,t}$ ——票价调整成本（来自 attendance_data.csv 的上座率数据）； $C_{media,t}$ ——媒体投入调整成本（来自 media_deals.csv 的 annual_value，复用第三问的媒体成本公式）； $C_{salary,t}$ ——薪资调整成本（来自 salary_cap_history.csv 的薪资帽数据，结合联盟薪资规则）。

$|\Delta Z_{\max}|$ ——理论最大损失（由核心球员全额伤病、无应对策略时的损失校准）；

$C_{response,max}$ ——理论最大应对成本（所有应对策略均执行时的成本）；

加权系数（0.6、0.4）：优先降低损失，其次控制成本，可根据球队战略（第三问的目标权重）动态调整。

8.3.5 约束条件（延续+新增，贴合联盟规则与数据）

1. 薪资帽约束：复用第三问修正后的薪资约束，

$$Cap_{min,t} \leq \sum_{i=1}^N s_i' \cdot x_{i,q} + C_{salary,t} \leq Cap_t;$$

2. 收购预算约束： $C_{acq,t} \leq Budget_{acq}' \cdot 0.3$ （紧急收购成本不超过修正后预算的 30%，

避免影响常规收购)；

3. 阵容人数约束： $12 \leq N + x_{new} \leq 15$ (x_{new} 为紧急收购替补人数，贴合联盟规则)；

4. 应对策略约束：

票价调整约束： $0.6 \leq a_2 \leq 1.0$ (伤病后仅可降价，不可涨价)；媒体投入约束：

$0.5 \leq a_3 \leq 1.2$ (可减少非核心媒体投入，或增加宣传降低伤病影响)；薪资调整约束：核心球员伤病期间降薪不超过 30% (联盟规则)，即 $s_{core,t} \geq 0.7 \cdot s_{core,0}$ 。

5. 时序约束：应对策略需随伤病持续时间动态调整，即 $|A_t - A_{t-1}| \leq 1$ (相邻场次应对策略调整不超过 1 个维度)。

8.3.6 算法设计（高级算法：MO-MARL 多目标强化学习）

本模块采用多目标强化学习 (MO-MARL)，适配“双最小化”目标，解决多维度应对策略的动态优化问题，与第三问的 MARL 算法衔接，同时提升算法复杂度与适配性：

1. 算法选型：采用基于 DQN 的多目标强化学习 (MO-DQN)，引入帕累托最优解概念，解决多目标冲突 (如“紧急收购替补可降低损失，但增加成本”)；

2. 智能体设计：构建单智能体，动作空间为应对策略组合

$A_t = [a_1, a_2, a_3, a_4]$ ，状态空间为 $(Y_t = [I_t, T_{perf,t}, R_{total,t}, Cap_t, Budget_{acq}, S_{market,t}])$ ；

3. 奖励函数设计 (适配多目标最小化)：

$$r_t = -(0.6 \cdot \frac{|\Delta Z_t|}{|\Delta Z_{max}|} + 0.4 \cdot \frac{C_{response,t}}{C_{response,max}}) + \lambda \cdot compliance$$

其中， $compliance$ 为约束满足度 (满足所有约束时为 1，违反 1 条约束减 0.2)， λ 为约束奖励系数 ($\lambda=0.1$)，确保智能体输出合规策略；

4. 模型训练与求解：

经验回放池：存储 (Y_t, A_t, r_t, Y_{t+1}) 经验，采用优先级经验回放 (PER)，优先采样损失大、策略效果好的经验；

网络结构：输入层 (状态维度=6) → 隐藏层 (2 层，各 128 个神经元，ReLU 激活函数) → 输出层 (动作维度=4，输出各策略的 Q 值)；

帕累托最优解筛选：训练过程中筛选帕累托最优策略组合，结合球队战略 (第三问的目标权重)，输出最终最优应对策略 A_t^* ；

训练终止条件：连续 150 轮迭代，奖励函数 r_t 收敛 (两次迭代差值 $\leq 1\%$)，且约束满足度 ≥ 0.8 。

5. 算法衔接：MO-MARL 的状态空间复用第三问 LSTM 预测的薪资帽 Cap_t 、市场份额 $S_{market,t}$ ，动作空间复用第二问的球员收购渠道、第三问的商业决策调整逻辑，确保与前文算法、模型无缝衔接。

8.4 算法集成与协同求解

第四问的两个核心子模块（票务定价优化、伤病危机应对）并非独立，而是存在协同关联（如伤病后需调整票务定价，票务定价优化需考虑伤病风险），因此需将两个模块的算法集成，实现协同求解，同时与前三问的算法体系形成闭环：

1. 算法集成框架：构建“时序预测-决策优化-危机应对”的三层集成框架

底层：Attention-LSTM（票务定价的上座率预测）+ 第三问 LSTM（薪资帽、市场份额预测），提供时序数据支撑；

中层：贝叶斯优化（票务定价系数优化），输出常规运营下的最优定价策略；

顶层：MO-MARL（伤病危机应对），当检测到核心球员伤病（ $I_t \geq 1$ ）时，触发应对策略，同步调整票务定价、媒体投入、球员收购等策略，实现协同优化。

2. 协同求解逻辑：

常规场景（无伤病， $I_t=0$ ）：执行 Attention-LSTM+贝叶斯优化，输出最优票务定价策略 $P_{t,m}^*$ ，更新球队利润（ Π ）与品牌估值 $V_{franchise}$ ，反馈至第三问的目标函数；

危机场景（有伤病， $I_t \geq 1$ ）：MO-MARL 智能体触发，基于当前状态 Y_t ，输出最优应对策略组合 A_t^* ，同步调整票务定价系数 a_2 （替代常规定价 $P_{t,m}^*$ ）、紧急收购策略（ a_1 ）（衔接第二问）、媒体投入 a_3 ，实时计算应对成本与损失，最小化 $G(A_t)$ ；

场景切换：伤病恢复后（ $I_t=0$ ），模型自动切换回常规场景，逐步调整定价、媒体投入等策略，回归常规运营，确保时序连续性。

3. 求解输出：

常规场景输出：各赛季、各场次的最优定价调整系数 $P_{t,m}^*$ 、门票净收益增量 $\Delta R_{ticket,t,m}$ 、季票增长率 $S_{season,t}$ ；

危机场景输出：最优应对策略组合 A_t^* 、伤病损失最小化值 L_t 、应对总成本 $C_{response,t}$ 、策略调整后的双目标值 Z_t ；

衔接输出：将第四问的优化结果（常规场景的收益增量、危机场景的损失控制）反馈至前三问的整体模型，更新目标函数值 Z ，实现全模型闭环。

8.5 模型验证与衔接说明

8.5.1 模型验证

1. 可行性验证：所有参数、变量均依托现有数据字段，无无数据支撑的假设；约束条件贴合 WNBA 联盟规则（薪资帽、阵容人数、伤病降薪等），策略组合（如紧急收购、票价调整）符合球队实际运营逻辑；

2. 稳定性验证：采用扰动分析法，对核心参数（injury_risk_coeff、

ticket_price_elasticity) 进行 $\pm 10\%$ 扰动, 观察目标函数值变化幅度, 要求变化幅度 $\leq 6\%$;

3. 算法验证:

Attention-LSTM: 预测误差 $MAE \leq 8\%$, 优于前三问的 LSTM, 确保上座率预测精度;

贝叶斯优化: 迭代收敛次数 ≤ 60 次, 最优定价策略的双目标值较前三问的固定定价提升 10%以上;

MO-MARL: 奖励函数收敛后, 伤病损失降低 30%以上, 应对成本控制在预算范围内, 约束满足度 ≥ 0.8 。

4. 衔接验证: 将第四问的模型嵌入前三问的整体模型, 对比“有无第四问优化”的目标函数值, 要求优化后 $Z_{new} \geq Z_{old} \cdot 1.05$ (常规场景)、 $Z_{crisis,new} \geq Z_{crisis,old} \cdot 1.3$ (危机场景), 验证模型的有效性与衔接性。

8.6 模型小结

第四问模型以“额外商业决策+伤病危机应对”为核心, 紧扣现有数据字段, 构建了逻辑严密、算法高级、衔接顺畅的完备模型。通过 Attention-LSTM+贝叶斯优化实现票务定价的时序动态优化, 通过 MO-MARL 实现核心球员伤病的多策略动态应对, 两大子模块协同求解, 形成“常规运营优化-突发危机应对”的闭环。

本模型严格延续前三问的建模风格、目标函数、约束条件与算法体系, 明确了各模块的数据来源与应用方式, 未引入无数据支撑的参数与假设, 既实现了第四问的场景需求, 又完善了整个题目(1-4问)的模型体系, 为后续第五问(给管理层的信)提供了坚实的模型支撑与策略依据。